

Sistemas de Inteligencia Artificial

TP: Algoritmos genéticos - Arquero 3

CARLA BARRUFFALDI, TOMÁS CERDÁ, LUCIANO BIANCHI, MARCELO LYNCH

Instituto Tecnológico de Buenos Aires

1. INTRODUCCIÓN

Se implementó un motor para realizar búsquedas por algoritmos genéticos con distintos métodos de selección, cruce y reemplazo. El motor se utilizó para buscar individuos privilegiados en un espacio de búsqueda discreto.

Se presenta en el siguiente informe un análisis de la aplicación de estos métodos a ese problema. El análisis se basó en realizar hipótesis razonables sobre la efectividad o idoneidad de los distintos métodos y la posterior contrastación de estas hipótesis con los datos experimentales (los resultados de correr el algoritmo).

2. IMPLEMENTACIÓN

La implementación fue realizada en *Python 3.6*. Se implementaron todos los métodos de selección, cruza, reemplazo y criterios de corte vistos en clase.

La función de probabilidad de mutación cuando la misma es no uniforme corresponde a $f(t) = p * e^{-0.001*t}$ si se escoge que la probabilidad disminuya con las generaciones, o $f(t) = p * (1 - e^{-0.001*t})$ si se elige que *aumente* con las generaciones siendo p un valor entre 0 y 1 fijo (la probabilidad de mutación máxima) y t la generación. La función de temperatura para el método de selección *Boltzmann* disminuye a lo largo de las generaciones t según $T(t) = \max\{1000 - t * 0.1, 0.1\}$. De esta forma los valores de la temperatura son elevados en las generaciones iniciales y menores en las más avanzadas.

Por último, para elegir los pares de individuos que deben cruzarse se eligen pares aleatorios de individuos del conjunto de individuos obtenido a partir del proceso de selección. Estos pares se eligen sin reemplazo, asegurando así que todos los individuos selectos forman parte de algún par.

3. PROBLEMA

El tipo de individuo que se analiza en este trabajo es el *Arquero 3*. El mismo tiene un multiplicador de 0.9 para el ataque y 0.1 para la defensa en el cálculo de su desempeño (fitness), y los siguientes multiplicadores para los *stats* de cada ítem:

Fuerza	Agilidad	Pericia	Resistencia	Vida
0.8	0.8	0.8	1.1	1.2

Observando que el desempeño del Arquero depende principalmente del parámetro ataque, se espera que a lo largo de las generaciones sobrevivan individuos con mayor fuerza, agilidad y pericia pues el ataque depende de estos, si bien los multiplicadores de estos parámetros son menores a los de resistencia y vida, que inciden en el parámetro de defensa únicamente.

4. METODOLOGÍA Y RESULTADOS

I. Datos de contraste

Para contrastar los resultados utilizando los algoritmos genéticos primero se hizo una búsqueda completamente aleatoria por el espacio de individuos (esto se logró en definitiva corriendo el motor con métodos de selección y reemplazo aleatorios, brecha generacional de 1 y probabilidad 1 de mutación). Se obtuvieron así 15000 veces 1000 individuos. Estas *poblaciones aleatorias* presentaron típicamente un fitness mínimo de entre 2 y 5 y un máximo entre los valores 12 y 22, con medias y medianas entre 8 y 9. El valor máximo de fitness observado entre todas las muestras fue de 25.54. Se tomarán estos valores como líneas de base para el análisis posterior.

II. Genotipos favorables

Resulta de interés analizar si los algoritmos encuentran algún patrón genético favorable en los individuos con alto fitness. A partir de las múltiples pruebas realizadas con diversas configuraciones se observa que el fitness máximo que logran los algoritmos antes de estancarse está típicamente entre 30 y 37. La figura 1 muestra una representación de los individuos, todos con fitness mayor a 30, seleccionados luego de correr algoritmo genéticos con distintas configuraciones¹.

Para el problema del Arquero, que es el que nos concierne, el fitness termina dependiendo mayormente del ataque, y por lo tanto maximizar esta característica resulta favorable. Esto puede verse en los individuos que se muestran en la figura 1, que presentan items con valores mas altos en fuerza, agilidad y pericia (que es lo que afecta el ataque). Algo muy interesante es que todos los individuos que se muestran tienen alturas de 1.91 o 1.92. La fórmula multiplicadora de ataque según la altura, $0.5 - (3h - 5)^4 + (3h - 5)^2 + \frac{h}{2}$, tiene un máximo en $h = 1.9152$. Esto vuelve a evidenciar contundentemente la importancia de maximizar el ataque en este problema.

III. Incidencia del tamaño de la población

Se buscó estudiar el efecto del tamaño de la población en la convergencia del algoritmo. Se espera que una población de mayor tamaño, dada una configuración que deja fija los demás factores (algoritmos de selección, probabilidad de mutación, etc.) permite una mayor exploración del espacio de individuos (tanto por una mayor población inicial, que al ser escogida al azar cubrirá mayor parte del espacio, como con las posteriores mutaciones) y mayor variabilidad.

Para verificar esto se compararon los resultados dejando fija la siguiente configuración:

Método de selección	Método de reemplazo	Selección en el reemplazo	Generation gap	Probabilidad de mutar
Ruleta	2	Elite	0.97	0.08

Se utilizó el método ruleta para tener exploración en la selección: por otro lado, el método 2 de reemplazo con *generation gap* alto, seleccionando con elite, permite que el fitness máximo crezca generación a generación (siempre sobrevive el de máximo fitness de la generación anterior) pero priorizando la renovación de la población con sus descendientes. Se utilizaron tres seeds diferentes (1, 2, 3) para los distintos casos. La tabla 1 muestra el máximo fitness obtenido tras 1500 generaciones, y también (en la columna *Generación umbral*) la cantidad de generaciones que se necesitaron para lograr un individuo con mayor fitness que 25.54, nuestro valor de referencia. Este dato pretende ser un dato correlacionando el tamaño de la población con efectividad en la búsqueda: valores más pequeños de este *umbral* indican una mejora temprana en las características de la población. Aunque esto también podría correlacionarse con una convergencia prematura, se espera poder corregir ese problema variando otros parámetros, como la probabilidad de mutación, o utilizando métodos híbridos; por lo tanto, consideramos deseable un valor bajo de este umbral.

Los resultados no son sorprendentes: poblaciones mayores tienen mayor diversidad y obtienen mejores resultados más rápido. Sin embargo, considerando que el tiempo de ejecución aumenta con la población, simplemente elegir poblaciones más grandes no resulta la alternativa definitiva en algoritmos genéticos: es interesante buscar la exploración via mutaciones y combinando métodos y no simplemente agrandando la población. Con esto, se decidió proceder utilizando poblaciones de 700, que arrojaron buenos resultados en estas pruebas.

IV. Incidencia del método de crossover

Los diferentes métodos de crossover permiten obtener distinto tipo de diversidad en las nuevas generaciones: el hecho de mantener genes contiguos o cruzarlos permite explorar patrones genéticos favorables. En principio, como ya observamos, en el arquero los genes funcionan de manera más o menos independiente, y no esperamos que un método de crossover se vea favorecido por sobre otro: un cruce uniforme, por ejemplo, da lugar a mayor exploración y diversidad, que combinado con métodos elite parece ser una buena estrategia en este problema. Sin embargo, podría suceder que cruces que mantienen contigüidad en los genes se acerquen más rápidamente a una buena solución (si preservan "paquetes" de buenos items entre generaciones).

Con estas consideraciones, se probaron los distintos métodos de crossovers con tres *seeds* distintas, en la siguiente configuración:

Método de selección	Método de reemplazo	Selección en el reemplazo	Generation gap	Probabilidad de mutar
Elite (2 %) + Ruleta (98 %)	2	Elite (2 %) + Ruleta (98 %)	0.8	0.05

El objetivo fue verificar si algún método favorecía la evolución: para eso se consideró la cantidad de generaciones hasta llegar a un fitness de 35. Los resultados, que se presentan en la tabla 2 no favorecieron ningún metodo por sobre otro, lo cual corresponde con las expectativas. Así, en los siguientes experimentos, entonces, no se prefirió particularmente ninguno de estos métodos, para agregar diversidad en los algoritmos.

V. Métodos de selección y reemplazo

Las pruebas iniciales (ya expuestas en este informe), en especial la búsqueda de "individuos buenos" con varios algoritmos (los presentados en la figura 1) parecen reforzar (como ya mencionamos) la premisa de que, al menos para este tipo de personaje, maximizar

¹ Como solo nos interesa ver aquí si existen patrones realmente generales, no se enumeran las configuraciones del algoritmo para cada individuo obtenido.

el ataque es primordial en el fitness. Así, suponemos que no existen patrones multigen que sean especialmente favorables: con este supuesto, es razonable esperar que favorecer la exploración, preservando pocos individuos buenos para "recordar" los mejores genes individuales, es positivo en este problema. Por otro lado, es posible que una mayor tasa de elite permita recombinar más genes favorables a lo largo de las generaciones, y que convenga entonces seleccionar bastantes individuos con este criterio.

Para comprobar esto se compararon los resultados de utilizar una proporción alta de *elite* en los métodos contra utilizar una proporción alta de *random*, los extremos opuestos entre rápida convergencia y exploración. Como antes, se utiliza el método 2 de reemplazo con una selección que incluye *elite*, para que el fitness máximo crezca generación a generación. El generation gap que se usó fue de 0.9 para también favorecer la exploración de nuevas combinaciones. La tasa de mutación se mantiene uniforme, con un valor de 0.1. El algoritmo corta cuando no se logra un aumento de fitness de 1 % tras 2000 generaciones.

En ambos casos se utilizó una proporción de 0.5 para cada método en la selección (random o elite), y se probó contra los siguientes:

- (a) ruleta
- (b) torneos probabilísticos

Las figuras 2, 3, 4, 5 muestran los resultados. Los box-plots se toman por cada décima parte del total de generaciones hasta el corte. Es interesante notar en los box-plots la tendencia de los métodos con elite a agrupar a la población hacia arriba, mientras que en los que usan random se encuentran mucho más distribuidos en fitnesses. Lo mismo puede observarse comparando las medias y medianas, que en el caso de random oscilan mucho más, lo que indican poblaciones más diversas. También es interesante observar que si bien las configuraciones que utilizan elite convergen más rápidamente, la convergencia es a valores altos, que solo con conseguir un poco de variabilidad logran subir a un buen valor final. Esto se contrasta con

Los fitness máximos obtenidos son, en cada caso:

Elite + ruleta	Elite + torneos	Random + ruleta	Random + torneos
37.2	36.38	33.1	34.1

Estos resultados favorecen la elección de elite como un método a utilizar para este problema. También se intentó combinando 50 % de elite con 50 % de random, pero los resultados no fueron mejores que combinando elite con ruleta o con torneos. Es razonable suponer que el alto generation gap, sumado a una tasa de mutación relativamente alta y a la exploración que aporta la ruleta, fue suficiente para explorar nuevas soluciones que aportaran al acervo genético.

El método de ruleta + elite se probó variando el porcentaje de selección y con varias seeds (poblaciones iniciales). Los resultados fueron buenos, con individuos de más de 36 de fitness en el momento del corte. Los mejores resultados se obtuvieron con la proporción 50 : 50.

VI. Boltzmann

Considerando los resultados anteriores, el método de Boltzmann parece un buen candidato para este problema: a medida que pasan las generaciones, el enfriamiento permite que el método se aproxime a elite, pero tiene una buena exploración inicial, cuando la temperatura es alta.

Se experimentó utilizando el método de selección de Boltzmann combinado con ruleta, con la misma condición de corte que la sección anterior, para distintas seeds, probabilidades de mutación (0.05, 0.08, 0.1, 0.15) y porcentaje de cada método (50 %, 60 %, 70 %, 80 %, 90 % y 100 % para Boltzmann). Para la selección de los individuos de la generación anterior que sobreviven (el generation gap sigue siendo 0.9) se combinó Boltzmann con Elite, como antes, para poder mantener el individuo de máximo fitness en la población.

En general los resultados fueron buenos, superando el fitness de 35 en todos los casos, aunque fue consistentemente mejor cuando la proporción de Boltzmann era de 0.5 a 0.7. Los mejores resultados:

Seed	Proporción Boltzmann	Probabilidad de mutación	Fitness	Generaciones
10	0.6	0.05	37.95	8965
10	0.6	0.15	37.07	5109
20	0.5	0.15	37.03	3176
20	0.6	0.15	36.99	6053
10	0.5	0.05	36.77	4994
10	0.7	0.08	36.74	7667

VII. Combinando elite con alta probabilidad de mutación

Los experimentos anteriores sugieren que la selección por elite es favorable para este problema: aún con el riesgo de convergencia prematura, se han obtenido buenos resultados. El agente para combatir la convergencia es la mutación. Así, nos interesó explorar la posibilidad de combinar un método de selección con alta proporción de *elite* con probabilidades de mutación cada vez más altas: una alta tasa de mutación, pero manteniendo siempre los mejores individuos, posiblemente permita salir de las "mesetas" que genera una convergencia prematura.

Para probar esto, se variaron la probabilidad de mutación entre las del conjunto $\{0.1, 0.2, 0.3\}$ y la proporción de elite entre las de $\{0.8, 0.9, 1\}$ (combinado con ruleta).

Esto resultó en convergencias a individuos un poco inferiores a los obtenidos usando Boltzmann, pero siempre por encima de 34. Los mejores resultados se dieron con probabilidades de mutación moderadas:

Seed	Proporción Elite	Probabilidad de mutación	Fitness	Generaciones
30	0.9	0.1	37.41	3531
10	0.8	0.1	36.53	8359
10	0.8	0.2	36.21	3330
10	1	0.2	36.42	4529
30	0.8	0.1	36.72	2981

VIII. Probabilidad de mutación variable

La posibilidad de variar la tasa de mutación, dados los resultados ya expuestos y utilizando las técnicas que resultaron favorables, abre caminos interesantes para probar. Si la probabilidad de mutación comienza baja y aumenta con el tiempo, podemos agregar un componente altamente exploratorio en generaciones avanzadas, convergiendo rápido al principio. Al contrario, disminuyéndola paulatinamente se puede explorar mucho al principio y combinar los mejores individuos al final sin mutarlos. Ambas posibilidades pueden ser buenas en este problema, juzgando por los resultados de las experiencias previas. Se probaron entonces ambas opciones, con distintas semillas iniciales, con un valor de probabilidad máximo en cada caso de 0.2. Los criterios de corte se mantuvieron como en las pruebas anteriores. Se utiliza 80 % elite y 20 % ruleta.

La variante de probabilidad creciente logró en el mejor caso un fitness de 35.68, cortando a las 4922 generaciones. La variante de probabilidad decreciente logró en el mejor caso un fitness de 36.58 cortando en 3614 generaciones. Probando con otros porcentajes de selección (como 50 : 50) no parece haber una ventaja clara entre las dos opciones, ni tampoco por sobre mutación constante.

Más allá de los resultados, resulta muy interesante observar como cambia la distribución de la población a lo largo de las generaciones con estos métodos. Las figuras 6 y 7 muestran los box-plots en distintas generaciones y las series temporales de máximo, mínimo, media y mediana para todas las generaciones. Es fácil ver con los box-plots la influencia de la tasa de mutación: aun cuando el máximo fitness es creciente en ambos casos, la figura 6 muestra como la población se concentra en fitnesses altos (de hecho la caja no se ve, y los valores bajos aparecen como *outliers*), mientras que la figura 7 muestra el comportamiento contrario. El cambio en la diversidad también puede notarse observando los gráficos de las medias y medianas: mientras más cerca del máximo se encuentran, la población tiene menor diversidad.

5. CONCLUSIONES

El desarrollo de este trabajo evidenció la complejidad de elegir el mejor tipo de algoritmo genético para un problema: la inmensa cantidad de posibilidades y la dependencia de la población inicial para el éxito de cada método se hicieron claras. Sin embargo, se lograron resultados consistentes y favorables utilizando las hipótesis planteadas.

Es claro que en este tipo de problemas la búsqueda por algoritmos genéticos es una buena opción, por la naturaleza discreta o discontinua del espacio de búsqueda: otros métodos de optimización (por ejemplo, *hill climbing*) son imposibles o poco prácticos para este problema. Sin embargo, también se ve que no hay una *mejor* forma de resolverlo con algoritmos genéticos: lo mejor fue finalmente intentar acotar las configuraciones del algoritmo que parecían adecuadas y probarlas: aún así los resultados difirieron mucho según la población inicial. El hecho de que probar configuraciones *al azar* resultara en buenos individuos (los mostrados en la figura 1) también es testimonio de esto.

6. APÉNDICE. TABLAS Y FIGURAS

Tabla 1. Distintos tamaños de población

seed	N	Fitness máxima (gen. 1500)	Generación umbral
1	50	32.52	51
	100	32.91	25
	300	34.34	16
	500	33.40	15
	700	36.28	12
	1500	36.23	7
	3000	35.20	7
2	50	30.53	77
	100	31.62	78
	300	35.44	41
	500	34.28	15
	700	35.45	18
	1500	35.87	14
	3000	36.00	14
3	50	30.85	28
	100	33.78	17
	300	34.71	8
	500	34.60	10
	700	34.46	8
	1500	36.94	8
	3000	37.25	8

Tabla 2. Distintos métodos de crossover

seed	Método	Gen hasta 35
1	One point	3907
	Two point	1416
	Anular	1302
	Uniform	4922
2	One point	3227
	Two point	1844
	Anular	286
	Uniform	1481
3	One Point	500
	Two point	3780
	Anular	2127
	Uniform	2412

Figura 1. Genotipos favorables. Colores más cercanos al verde corresponden con valores más altos, y más cercanos al rojo con valores bajos. Las primeras cinco filas de cada matriz corresponden a los ítems: de abajo hacia arriba, botas, arma, casco, guantes, armadura. El coloreo de las columnas para los ítems corresponden, de izquierda a derecha, con fuerza, agilidad, pericia, resistencia y vida. La última fila corresponde a la altura (y se colorean todas las columnas igual).




Figura 2. Elite y ruleta. El eje vertical representa el fitness. En la serie temporal, en el eje horizontal se encuentran las generaciones. Cada box plot esta etiquetado con la generación a la que corresponde en la parte superior.

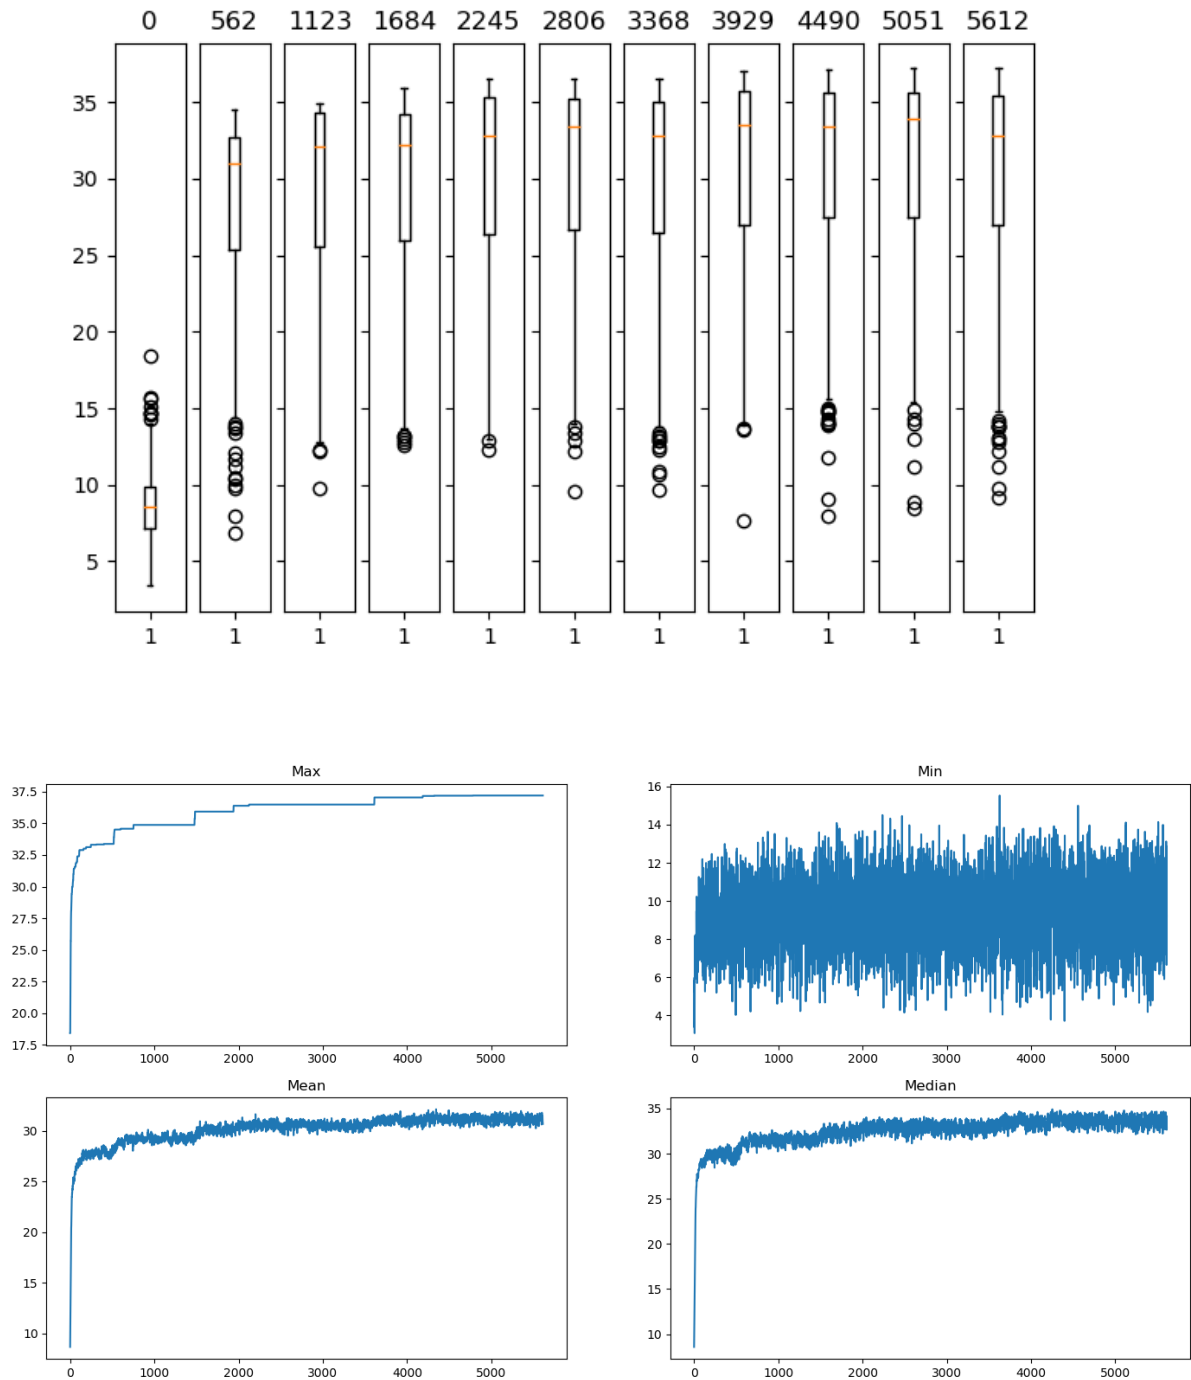


Figura 3. Elite y torneos. El eje vertical representa el fitness. En la serie temporal, en el eje horizontal se encuentran las generaciones. Cada box plot esta etiquetado con la generación a la que corresponde en la parte superior.

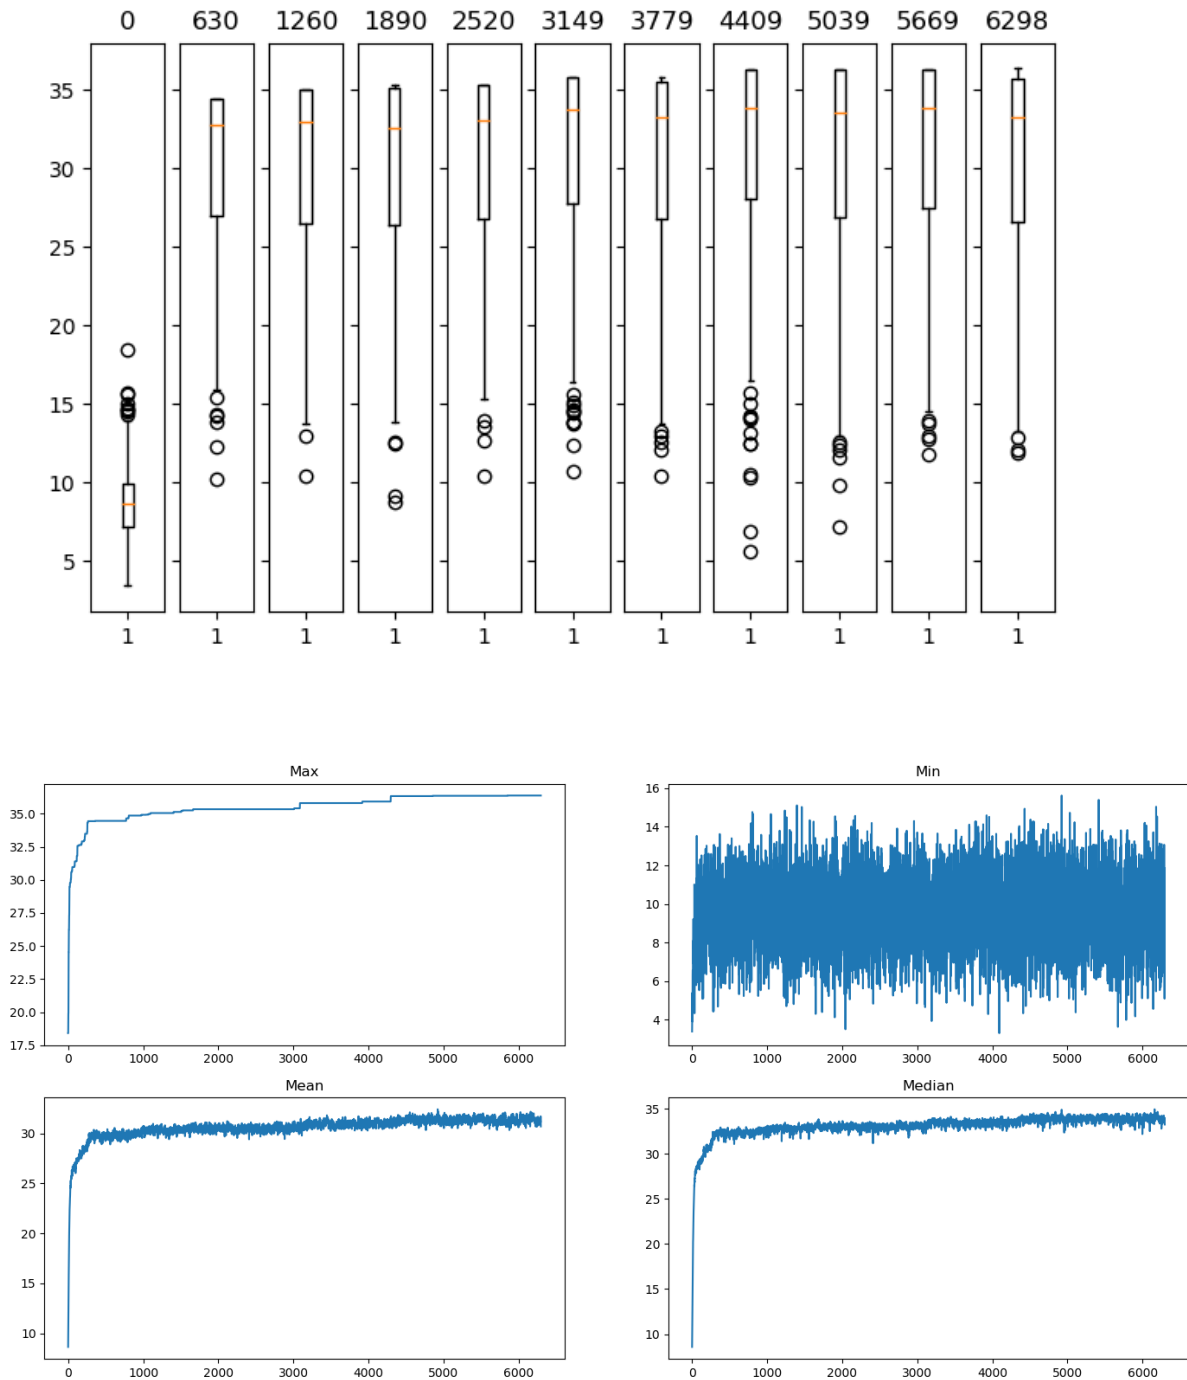


Figura 4. Random y ruleta. El eje vertical representa el fitness. En la serie temporal, en el eje horizontal se encuentran las generaciones. Cada box plot esta etiquetado con la generación a la que corresponde en la parte superior.

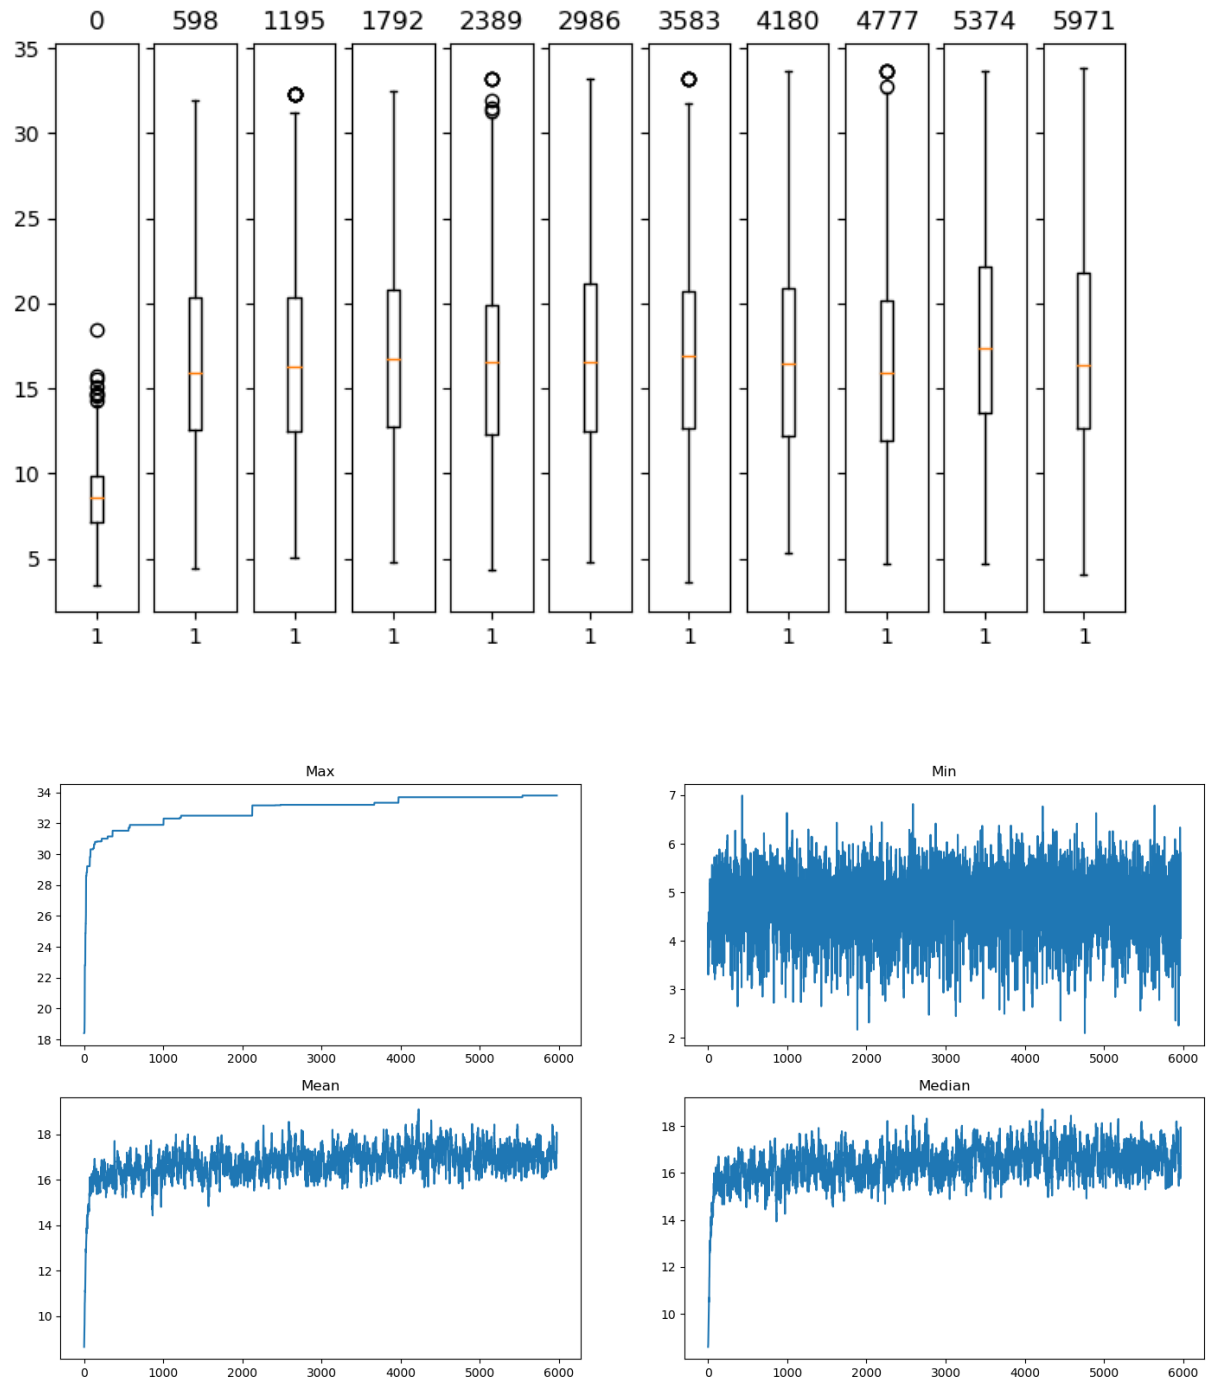


Figura 5. Random y torneos. El eje vertical representa el fitness. En la serie temporal, en el eje horizontal se encuentran las generaciones. Cada box plot esta etiquetado con la generación a la que corresponde en la parte superior.

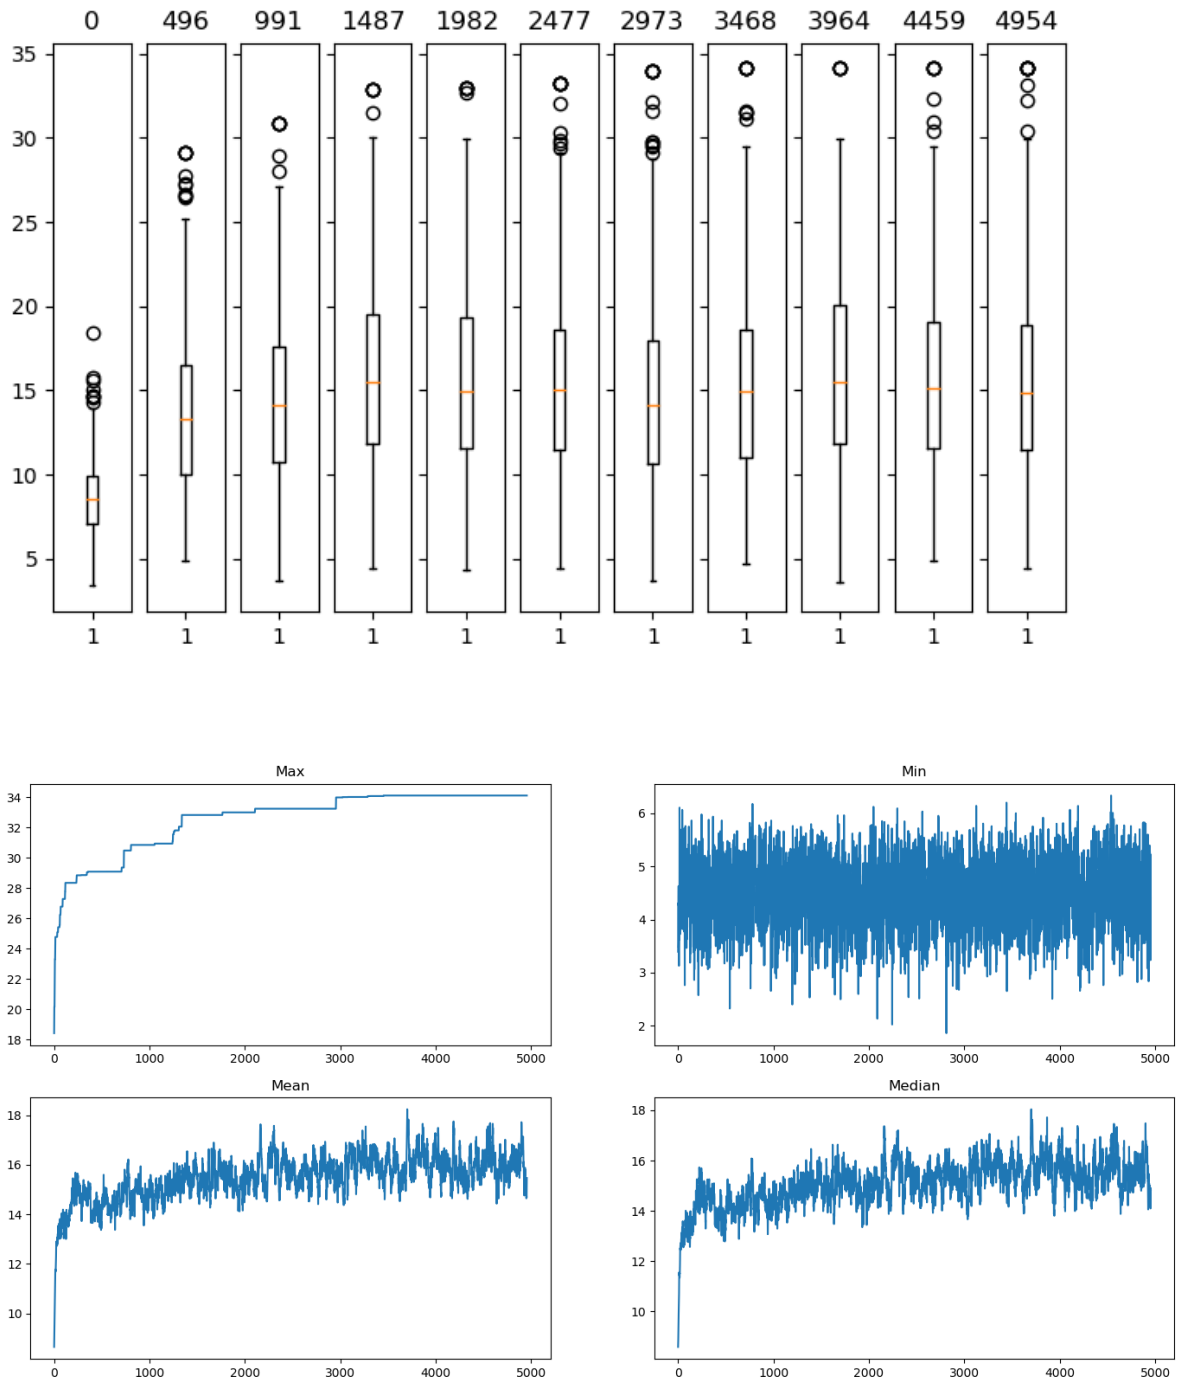


Figura 6. Probabilidad de mutación decreciente. Se nota la dominancia del metodo elite sin mutación: la población se concentra en el tope y se presentan muchos *outliers*

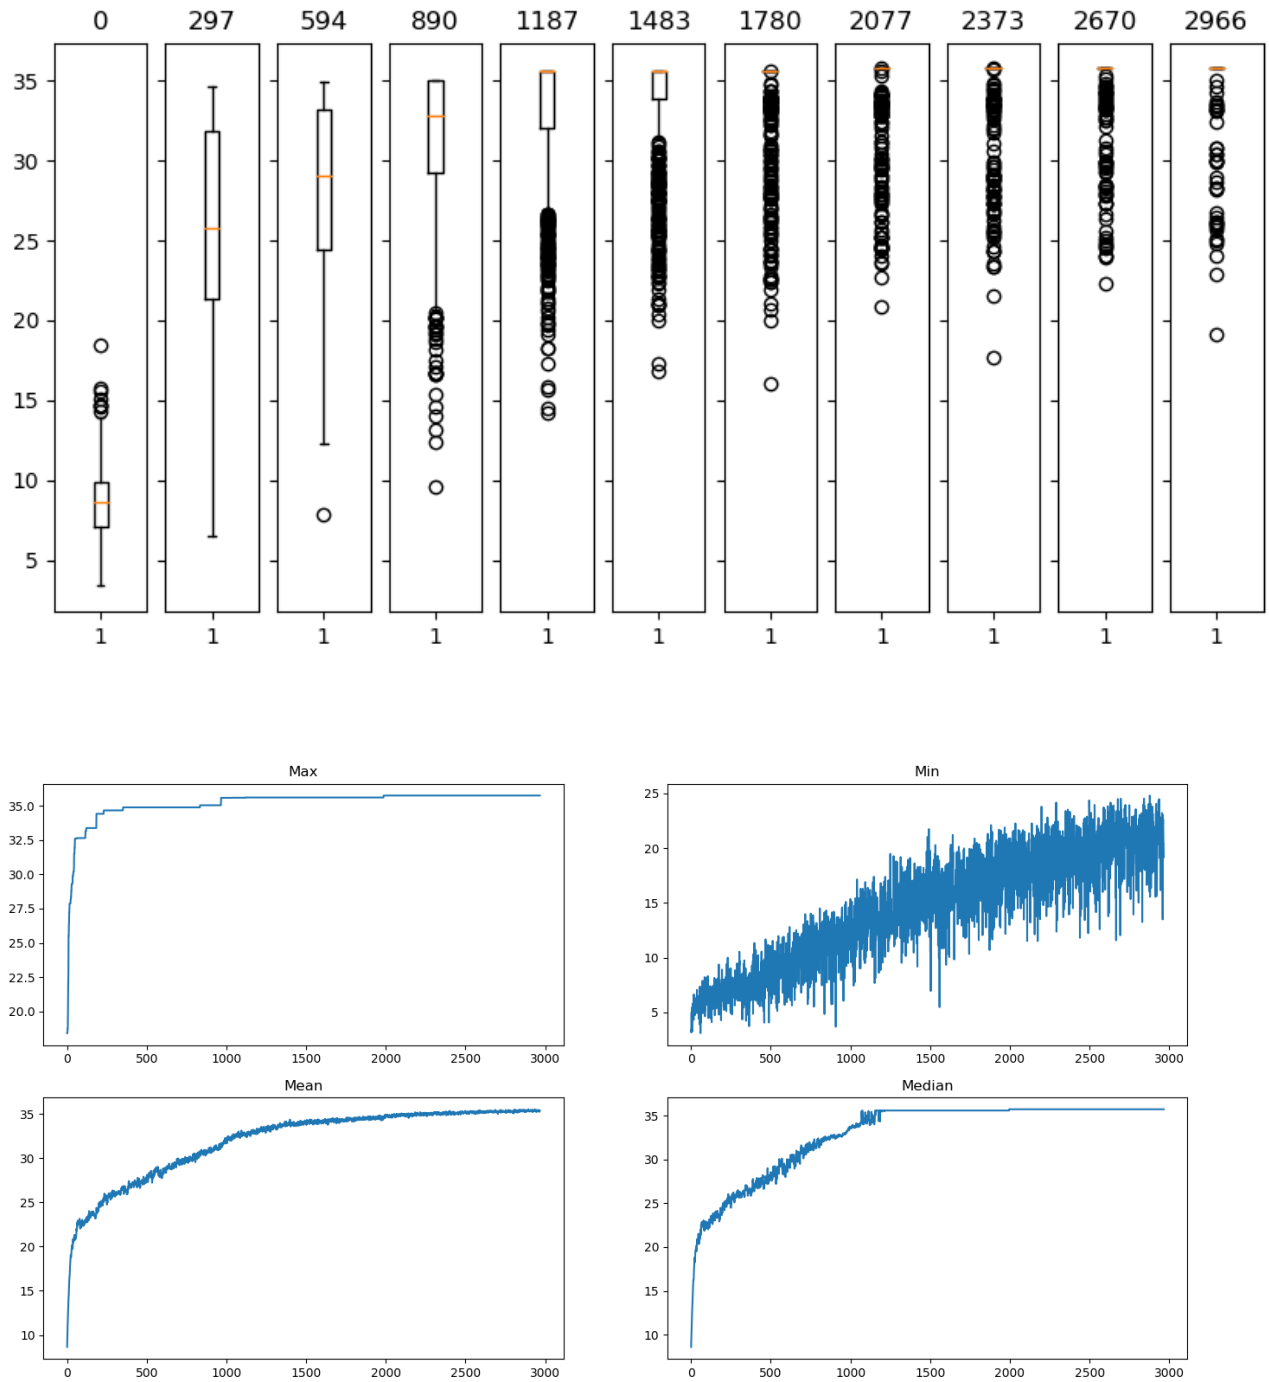


Figura 7. Probabilidad de mutación creciente. Se nota como crece la diversidad a medida que aumenta la tasa de mutación

